

MGR-SID: 面向生成式推荐的 层级感知图正则化语义ID

Anonymous authors

Paper under double-blind review

ABSTRACT

生成式推荐的效果高度依赖item tokenizer，因为它决定了每个item 如何被映射为离散语义ID。近期已有不少工作意识到collaborative information 应当进入tokenizer，但它们大多把协同信号看作一种全局统一表示，再在整个tokenizer 中统一融合。我们对MiniOneRec 的系统分析表明，这种framing 对层级语义ID 仍然过于粗糙。我们发现，在最终sid-generate 之后，完整SID 的collision 已经处于很低水平，当前的主要瓶颈并不是未修复的全局碰撞，而是发生在语义前缀内部的局部歧义：prefix 往往已经正确，但最后一层leaf token 仍然难以稳定预测。基于这一观察，我们提出**MGR-SID**，一种建立在MiniOneRec 语义RQ-VAE backbone 之上的层级感知图正则化tokenizer。当前的v1 实例包含一个仅用训练数据构造的graph bank，其中包括净化后的coarse collaborative graph、spectral middle-resolution graph 以及净化后的local transition graph，并在不同SID level 上施加不同的图结构约束。首先，我们在Industrial 和Office 上通过probe 证明：spectral middle-resolution graph 在same- l_2 歧义桶上的判别力显著强于第一版heuristic middle view。随后，我们将tokenizer 训练制度对齐到上游MiniOneRec，并在公平设定下验证训练时graph regularization。Industrial 上，层级图正则将最终生成index 的collision 从0.00353 降到0.00326，并把测试目标落在多叶same- l_2 bucket 的比例从68.94% 降到61.31%。把这套SID 推进到下游SFT 后，我们得到一个更细致的结果：hierarchy-aware tokenizer 在短程排序上带来提升（NDCG@3：0.0777 $\rightarrow$ 0.0802），同时减少了evaluate 阶段的same-prefix 错误，但在更广义的@10+ 指标上还没有全面超过semantic baseline。整体来看，这些结果说明，相比统一的graph feature fusion，graph-structured collaboration 更适合作为level-specific 的结构监督进入SID 学习，但tokenizer 到SFT 的传递机制仍然只解决了一部分问题。

1 引言

生成式推荐把“在候选集合上做打分排序”改写成“在item code 序列上做自回归生成”。这一范式越来越受到关注，因为它可以直接继承语言模型的训练与解码机制。TIGER、LCRec 以及MiniOneRec 等工作已经证明，离散item tokenizer 可以作为item 语义与自回归推荐之间的桥梁(Rajput et al., 2023; Zheng et al., 2023; Kong et al., 2025)。一旦tokenizer 被固定下来，它的结构偏置就会被整个下游链路继承，包括constrained decoding、SFT 以及推荐导向RL。

因此，tokenizer 不是简单的预处理步骤，而是会直接限制系统上限的核心模块。在我们当前的MiniOneRec 复现与后续研究中，持续出现了一个并不符合“collision 是主问题”这一常见叙事的现象。经过官方sid-generate 冲突修补之后，最终SID 的collision 已经处在sub-percent 水平，但推荐错误仍然大量存在。进一步诊断发现，许多错误并不是模型跑到了完全错误的语义子树，而是已经进入了正确或近似正确的前缀区域，最后却在leaf token 上出错。换句话说，prefix 经常是对的，但最后一层leaf 不够稳定。这说明当前真正剩下的tokenizer 瓶颈更像是语义合理前缀内部的局部歧义。

与此同时，现有collaborative tokenizer 工作已经表明，协同信息确实应该进入item tokenization，但它们大多通过一个全局统一的collaborative representation 来实现(Fang et al., 2026; Liang et al., 2026; Wang et al., 2026; Liu et al., 2025)。对于flat representation，这种处理很自然；但对于hierarchical semantic ID，它可能仍然过于粗糙。不同SID level 天生承担不同角色：高层更像粗粒度routing，中层更像subgroup organization，底层更像local leaf discrimina-

tion。把同一种协同视图均匀复用到每一层，不仅可能不够精确，还可能引入不必要的不稳定性。

基于这一判断，本文提出**MGR-SID**：一种层级感知、图正则化的semantic ID 方法。MGR-SID 不替换MiniOneRec 的语义RQ-VAE tokenizer，而是在其基础上引入一个train-only graph bank，把图结构作为协同信息的载体。当前v1 的实现包含三类图视图：净化后的coarse collaborative graph、spectral middle-resolution graph 以及净化后的local transition graph。与长期愿景中的“learned allocation”不同，当前v1 采取一个更保守但清晰的层级实例化方式：level 1 接coarse graph 正则，level 2 接spectral middle view，level 3 接local transition graph。

本文的证据链分四步展开。第一，我们在Industrial 和Office 上进行不改tokenizer 本体的graph probe，证明middle-resolution graph 是必须被显式设计的，且spectral middle view 明显优于heuristic middle view。第二，我们系统回溯MiniOneRec tokenizer 的provenance，证明公平比较必须使用上游官方RQ-VAE 训练制度，而不是当前本地默认配置。第三，在这一公平设置下，我们验证训练时graph regularization，发现hierarchy-aware 版本虽然在raw sid-train collision 上不占优，却在最终sid-generate 后的SID 质量上优于语义baseline。第四，我们将新的SID 推进到Industrial SFT，发现其收益可以部分传递到下游：短程排序和same-prefix 错误分布出现改善，但广义的end-to-end 指标还没有形成全面优势。

当前稿件仍然以tokenizer 阶段为中心，但已经包含了第一轮下游SFT 传递实验。我们暂时不主张已经得到新的end-to-end 最优系统，也不主张RL 阶段已经受益。我们的目标是先把tokenizer 侧的因果链条建立清楚，再定位这些结构收益在下游为什么只得到了部分保留。

本文贡献。

1. 我们识别出MiniOneRec 当前tokenizer 的主瓶颈：在公平复现上游tokenizer 之后，剩余难点主要不是全局collision，而是local leaf ambiguity。
2. 我们提出MGR-SID，一种将graph-structured collaborative information 以level-specific structural supervision 的方式注入semantic tokenizer 的方法，而不是使用统一的feature fusion。
3. 我们给出当前阶段已完成的实证证据：在Industrial 上，upstream-aligned 的hierarchy-aware tokenizer 把最终生成SID 的collision 从0.00353 降到0.00326，并显著改善same- l_2 局部歧义结构；相比之下，uniform graph regularization 明显有害。把该tokenizer 推进到SFT 后，短程排序和same-prefix 错误分布进一步改善，但整体@10+ 指标尚未形成全面优势。

下文组织如下。Section 2 介绍相关工作。Section 3 总结tokenizer pipeline 与问题定义。Section 4 介绍当前MGR-SID v1 方法。Section 5 汇报probe、provenance alignment、tokenizer 阶段实验以及第一轮下游SFT 分析。Section 6 给出结论、限制以及后续如何改进tokenizer-to-SFT transfer。

2 相关工作

生成式推荐与语义item ID。近年来，生成式推荐通过离散item token 序列来重写推荐问题。TIGER 将generative retrieval 引入推荐场景，证明了通过item code 序列做自回归生成可以替代传统ranking (Rajput et al., 2023)。LCRec 把collaborative semantics 融入大语言模型适配，说明tokenized item representation 可以自然接入language-model pipeline (Zheng et al., 2023)。MiniOneRec 则进一步提供了覆盖semantic ID 构建、SFT、RL 与评估的完整开源框架(Kong et al., 2025)。这些工作共同表明tokenizer 在生成式推荐里是第一等问题，但它们大多沿用了semantic-first 的tokenizer 视角。本文仍然工作在MiniOneRec 主链内部，只是把问题进一步收紧为：在hierarchical semantic ID 中，协同结构到底应以什么方式进入tokenizer。

协同感知的tokenizer 设计。越来越多的工作开始指出，纯文本语义并不足以支撑高质量item tokenization。ReSID 从prefix-conditional predictability 的角度论证了recommendation-native tokenizer 的必要性(Liang et al., 2026)。PRISM 提出了purified collaborative representation 与semantic anchoring，强调noisy collaboration 会破坏tokenizer 稳定性(Fang et al., 2026)。PIT 则进一步指出collaborative signal 自身具有volatility，并研究动态个性化tokenizer (Wang et al., 2026)。DiscRec 将semantic 与collaborative factors 解耦后再融合(Liu et al., 2025)。这些方法都说明collaboration 应当进入tokenizer，但它们仍未真正回答一个对层级SID 尤其关键的

问题：不同SID level 是否应该使用不同的协同结构，而不是复用同一个全局collaborative representation。

超越reconstruction 的tokenization objective。另一条相关路线开始强调tokenizer 不应只为reconstruction 服务，而应直接为推荐结构服务。ETEGRec 提出end-to-end 可学习item tokenization，强调tokenization 与recommendation objective 应当被联合考虑(Liu et al., 2024)。CoST 利用contrastive quantization 提升面向生成式推荐的semantic tokenization (Zhu et al., 2024)。这些工作与本文在精神上很接近，因为它们都把推荐结构写回tokenization objective 中。不同之处在于，我们使用的是显式的graph-structured collaborative targets，并试图在不同SID level 上保留不同类型的结构，而不是通过单一目标统一约束所有关系。

图信号处理与transition-aware recommendation。MGR-SID 的graph bank 设计还受到图信号处理工作的启发。GSPRec 通过谱域分解区分不同graph frequency 对推荐的作用(Rabiah & McAuley, 2025)，FaGSP 则系统研究了collaborative filtering 中的frequency-aware graph signal processing (Xia et al., 2024)。与此同时，Collaboration and Transition 说明长程collaborative structure 与短程transition structure 并不是彼此替代的，它们在sequential recommendation 中承担不同角色(Zhu et al., 2023)。这些工作本身并不是semantic ID tokenizer，但它们为本文提供了关键线索：对hierarchical SID 来说，最有价值的协同信息很可能是multi-resolution 的，其中middle-scale graph structure 应当被显式建模，而不是被粗暴地夹在global 与local 之间。

本文的位置。MGR-SID 并不试图成为一个更强的通用graph encoder，也不打算一步到位做成fully personalized dynamic tokenizer。当前v1 是刻意收窄的：它继承MiniOneRec 的semantic RQ-VAE backbone，借鉴PRISM 的去噪纪律与semantic anchor，借鉴ReSID 的层级可预测性动机，并通过GSPRec/FaGSP 启发下的middle-resolution graph 来实例化graph-aware supervision。因而，本文真正的中心不是“更强的graph feature”，而是level-specific graph supervision for semantic ID learning。

3 背景与问题定义

3.1 MINIONEREC TOKENIZER PIPELINE

设每个item i 对应一个语义embedding $\mathbf{x}_i \in \mathbb{R}^d$ 。MiniOneRec 首先在这些item embedding 上训练一个RQ-VAE，然后将每个item 编码成固定长度的semantic ID，记为 $\text{SID}(i) = [z_i^{(1)}, z_i^{(2)}, z_i^{(3)}]$ (Kong et al., 2025; Lee et al., 2022)。在sid-train 阶段，模型学习对语义空间进行残差量化；在sid-generate 阶段，系统再对colliding items 启用Sinkhorn-based reassignment 进行多轮重编码，从而显著降低最终导出的index.json collision。

这一点很重要。tokenizer 的质量不能只看sid-train 阶段的raw collision，因为真实pipeline 最终使用的是sid-generate 之后的index。因此，公平的tokenizer 比较必须落在最终导出的SID 上，而不是只看训练器中间指标。

3.2 为什么当前更像LOCAL AMBIGUITY 问题

我们对当前semantic baseline 的分析持续指向同一个失败模式：许多错误发生在模型已经进入正确语义区域之后。更具体地说，第一层甚至前两层prefix 往往是正确的，但最后一层leaf token 仍然出错。于是，当前剩余难点更像是语义合理前缀内部的局部歧义。

为此，我们把两级前缀($z_i^{(1)}, z_i^{(2)}$) 相同的item 集合称作same- l_2 bucket。如果某个prefix 下仍然挂着很多leaf，那么即使上层routing 已经正确，生成器在最后一步仍然要面对困难的局部判别。基于这一观察，本文除了报告collision 之外，也把same- l_2 的拥挤程度和给定prefix 条件下第三级code 的条件熵当作tokenizer 健康度指标。

3.3 公平比较要求对齐上游训练制度

在比较graph-aware tokenizer 之前，我们首先遇到了一个provenance 问题。用当前仓库默认配置直接fresh rerun sid-train $\rightarrow$ sid-generate，会得到非常高的collision，这与仓库中已经存在的Industrial 正式index 明显不符。通过逐步对比本地代码与上游MiniOneRec 官方

Table 1: Industrial 上tokenizer provenance 对齐结果。只有使用上游风格RQ-VAE 训练制度，才能复现当前仓库正式tokenizer 的低collision 质量。

设定	Epochs	Batch size	最佳train collision	最终index collision
本地默认fresh rerun	10	256	0.9989	0.9940
上游风格fresh rerun	10000	20480	0.0993	0.00434
仓库正式Industrial index	—	—	—	0.00434

仓库，并重新用上游训练制度跑一遍Industrial tokenizer，我们确认问题主要来自超参数而不是实现损坏。

Table 1 是本文后续实验的前提。它说明，任何tokenizer-side 方法比较都必须建立在upstream-aligned 的训练制度之上，否则连baseline 都是不公平的。因此，本文所有训练时的MGR-SID 比较都采用与上游MiniOneRec 一致的RQ-VAE 训练设置。

3.4 问题定义

基于这些事实，本文关注的问题不再是泛泛的“是否要把collaboration 融进tokenizer”，而是：

在不破坏semantic hierarchy 的前提下，graph-structured collaborative information 应该怎样以层级感知的方式进入不同SID level，从而降低local ambiguity?

当前MGR-SID v1 对这一问题的回答是保守而清晰的：保留语义RQ-VAE backbone，不去替换semantic tokenizer，而是把图结构作为level-specific structural supervision 注入到tokenizer 学习过程中。

4 方法

4.1 方法概览

MGR-SID 保留MiniOneRec 的语义RQ-VAE tokenizer，并在其上增加一个train-only graph bank。核心直觉很简单：不同SID level 解决的是不同的结构判别问题，因此它们应当保留不同类型的协同图结构。当前v1 采用一个固定但非均匀的层级分配方式：

- level 1 使用coarse collaborative graph;
- level 2 使用spectral middle-resolution graph;
- level 3 使用local transition graph。

这一设计刻意比“完整learned allocation”更简单。v1 的目标不是直接做到最终形态，而是先验证：层级感知的图结构监督 本身是否已经有价值。

4.2 语义BACKBONE

给定item embedding $\mathbf{x}_i$ ，encoder 先将其映射到latent space，然后由三个残差量化器依次离散化。记第 l 层量化器输出为 $\mathbf{q}_i^{(l)}$ ，则第 l 层之后的累计量化表示为

$$\mathbf{h}_i^{(l)} = \sum_{r=1}^l \mathbf{q}_i^{(r)}. \quad (1)$$

decoder 根据 $\mathbf{h}_i^{(3)}$ 重构 $\mathbf{x}_i$ 。这一语义tokenizer backbone 与MiniOneRec 保持一致，我们不修改其reconstruction loss 和residual quantization loss。

4.3 GRAPH BANK 构造

所有图视图都只使用训练交互构造。对于每条训练样本，其最近历史为 $H_t = [i_{t-k}, \dots, i_{t-1}]$ ，目标item 为 y_t 。我们构造三类图。

Coarse collaborative graph. 我们把最近窗口内的历史item 与目标item 组成无向item-item 协同图。若两个item 在同一序列窗口内共现，则按相对距离的倒数给边赋权。这个图描述broad compatibility 与稳定协同组织。随后我们做support pruning、popularity debias 和row normalization:

$$\mathbf{A}_{\text{coarse}} = \text{RowNorm}(\text{Debias}(\text{Prune}(\mathcal{G}_{\text{coarse}}))). \quad (2)$$

当前实现中，coarse edge 的最小保留阈值为2.0，popularity debias 指数为0.5。

Local transition graph. 我们从最近历史item 指向目标item 构造有向转移图。每条边按inverse-rank 加权，因此越近的历史item 权重越大。净化后的local graph 包含support pruning、target-popularity correction 与row normalization:

$$\mathbf{A}_{\text{local}} = \text{RowNorm}(\text{TargetDebias}(\text{Prune}(\mathcal{G}_{\text{local}}))). \quad (3)$$

这一视图直接描述短程next-item preference，但它天然更稀疏、更容易受噪声影响。

Middle-resolution graph. Middle view 是当前方法中最关键的设计点。早期heuristic probe 已经说明middle-scale structure 是必要的，但diffusion residual 和简单band-pass proxy 仍然偏弱。基于后续spectral probe，我们在当前v1 中将 G_{mid} 实例化为FaGSP 风格的谱域中尺度视图:

$$\mathbf{A}_{\text{mid}} = \text{BandReconstruct}(\text{SymNorm}(\mathbf{A}_{\text{coarse}})). \quad (4)$$

具体实现上，我们对purified coarse graph 做谱分解，保留中间频带上的特征分量进行重建。当前设置使用rank 48 和eigen-ratio 范围[0.25, 0.65]。我们还测试了GSPRec 风格的temporal spectral middle view，作为备选middle candidate，但当前主要结果使用的仍是FaGSP 风格spectral graph。

Semantic-anchor purification. 受PRISM 启发，我们还测试了semantic-anchor purification: 先在语义embedding 上构造top- k semantic k NN graph，再与净化后的协同图做交集与混合。这个模块对部分图视图有帮助，但probe 结果表明，真正的大幅提升主要来自middle-resolution graph 本身的质量，而不仅仅是anchor-only denoising。当前训练版v1 采用的最终middle view，是建立在purified coarse graph 上的spectral graph。

4.4 层级感知图正则

语义backbone 原本已经优化

$$\mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{rq}}, \quad (5)$$

其中 $\mathcal{L}_{\text{rec}}$ 是reconstruction loss， $\mathcal{L}_{\text{rq}}$ 是residual quantization loss。MGR-SID v1 在此基础上，对每层累计量化表示 $\mathbf{h}_i^{(l)}$ 增加图正则。

对于一个mini-batch $\mathcal{B}$ 及其对应的图子邻接矩阵 $\mathbf{A}_{\mathcal{B}}^{(l)}$ ，我们定义

$$\mathcal{L}_{\text{graph}}^{(l)} = \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} \left\| \mathbf{h}_i^{(l)} - \sum_{j \in \mathcal{B}} \mathbf{A}_{\mathcal{B}, ij}^{(l)} \mathbf{h}_j^{(l)} \right\|_2^2. \quad (6)$$

它鼓励在第 l 层被该图连接的item 在累计量化表示上保持局部平滑。直观来说，被当前层关注的图结构连接在一起的item，应当更容易在该层保持一致或相近的离散结构。

于是，hierarchy-aware v1 的总目标为

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{rec}} + \mathcal{L}_{\text{rq}} + \lambda_1 \mathcal{L}_{\text{graph}}^{(1)} + \lambda_2 \mathcal{L}_{\text{graph}}^{(2)} + \lambda_3 \mathcal{L}_{\text{graph}}^{(3)}, \quad (7)$$

其中

$$\mathbf{A}_{\mathcal{B}}^{(1)} \leftarrow \mathbf{A}_{\text{coarse}}, \quad \mathbf{A}_{\mathcal{B}}^{(2)} \leftarrow \mathbf{A}_{\text{mid}}, \quad \mathbf{A}_{\mathcal{B}}^{(3)} \leftarrow \mathbf{A}_{\text{local}}. \quad (8)$$

当前实现使用 $(\lambda_1, \lambda_2, \lambda_3) = (0.05, 0.15, 0.05)$ 。

Table 2: same- l_2 bucket 上的最佳middle-view probe 结果。spectral middle view 明显强于第一版heuristic middle view, 这也是MGR-SID v1 采用spectral G_{mid} 的直接原因。

数据集	最佳heuristic middle view	最佳spectral middle view	spectral 视图名称
Industrial	0.2747	0.5401	fagsp_mid_base
Office	0.2381	0.7619	fagsp_mid_base

4.5 控制组

为了隔离“层级感知”本身的作用, 我们设置两个直接对照:

- **语义baseline:** 只保留upstream-aligned MiniOneRec RQ-VAE tokenizer, 不加任何graph regularization;
- **uniform regularization:** 把coarse、mid、local 三种图简单平均, 只在最终累计表示上加一个统一graph smoothness loss。

uniform control 保留了相同的图材料, 但去掉了层级非均匀分配。因此它是检验“是否真的需要level-specific supervision”的最直接控制组。

4.6 当前方法范围

需要强调的是, 当前MGR-SID v1 仍然是tokenizer-stage 的实例化, 而不是最终形态。它还没有学习graph allocation 本身, 也还没有推进到SFT 或RL。本文的目标更窄: 先验证graph-structured collaborative information 作为level-specific structural supervision 是否能真正改善semantic tokenizer。

5 实验

5.1 实验设置

数据集。 我们使用当前MiniOneRec 复现主线中已经准备好的Industrial 和Office Amazon 数据集。Industrial 包含36,259 条训练交互、4,533 条测试交互和3,686 个item; Office 包含38,924 条训练交互、4,866 条测试交互和3,459 个item。两者都沿用仓库中的时间划分。

Tokenizer backbone。 除非特别说明, 本文所有训练时tokenizer 比较都使用与上游MiniOneRec 对齐的RQ-VAE 训练制度: 三层量化器、每层codebook 大小为256、量化embedding 维度为32、AdamW、学习率 10^{-3} 、训练10,000 epochs、batch size 为20,480。

评估指标。 我们报告三类指标:

- **Probe** 指标: 不同ambiguity bucket 上的target-better rate, 重点关注same- l_2 ;
- **Tokenizer** 指标: 最佳train-stage collision、最终sid-generate collision, 以及最大冲突大小;
- **局部歧义指标:** 平均目标 l_2 叶子数、目标落入多叶same- l_2 bucket 的比例、目标落入深拥挤same- l_2 bucket 的比例, 以及在固定前缀下第三级code 的条件熵。

5.2 设计空间PROBE: SPECTRAL MIDDLE VIEW 的必要性

我们首先做不改tokenizer 本体的graph probe。给定一个现有top-1 SID 错误样本, 我们比较某个graph view 是否更偏向真实target, 而不是当前被错误偏好的候选。这样可以在接入训练之前, 直接检查不同图视图对local ambiguity 的判别力。

Table 2 说明, 真正值得被显式设计的是middle-resolution graph structure 本身。对same- l_2 歧义而言, 最佳spectral middle view 在Industrial 上几乎把heuristic middle view 的判别力提升到了两倍, 在Office 上甚至超过三倍。这一结果直接推动我们把 G_{mid} 从heuristic proxy 升级为spectral graph。

Table 3: Industrial 上的tokenizer 比较结果。只看sid-train 会得出误导性结论；真正的排序应当看最终sid-generate 后的SID。

方法	最佳train collision	最终index collision	Max conflict
Semantic baseline	0.1066	0.00353	2
Uniform graph regularization	0.2458	0.00597	6
Hierarchy-aware MGR-SID v1	0.1319	0.00326	2

Table 4: Industrial 上最终SID 的局部歧义比较。Hierarchy-aware tokenizer 在catalog 级和test-weighted 两种口径下都降低了same- l_2 的拥挤程度。

指标	Baseline	Hierarchy	Delta
Mean target l_2 leaf count	4.7999	4.4498	-0.3501
Fraction targets in multi-leaf l_2	0.6894	0.6131	-0.0763
Fraction targets in l_2 with ≥ 4 leaves	0.3283	0.2828	-0.0454
Mean target level-3 entropy under l_2	1.4533	1.2935	-0.1598

5.3 在UPSTREAM-ALIGNED TOKENIZER 训练上的正式比较

接下来我们测试图信号进入tokenizer 学习后是否仍然成立。这里所有方法都使用Table 1 中已经验证过的upstream-aligned 训练制度。我们比较semantic baseline、uniform graph regularization, 以及hierarchy-aware 的MGR-SID v1。

Table 3 给出两个重要事实。第一, uniform graph regularization 明显有害, 说明“把graph 加进去”本身并不够。第二, train-stage collision 与最终tokenizer 质量并不一致。虽然semantic baseline 在raw sid-train collision 上最好, 但经过官方sid-generate 后, hierarchy-aware tokenizer 反而得到最好的最终SID。这也再次说明, tokenizer 比较必须落在最终导出的index 上。

5.4 最终TOKENIZER 是否真的降低了LOCAL AMBIGUITY

仅有更低的final collision 还不够, 我们还需要确认它是否真的改善了我们最关心的失败模式。为此, 我们直接比较baseline final index 与hierarchy final index 在same- l_2 层面的结构差异。

Table 4 表明, 这不是简单的code re-permutation。Hierarchy-aware tokenizer 的确让same- l_2 bucket 更干净: 目标item 平均面对的 l_2 叶子数更少, 落在多叶与深拥挤same- l_2 bucket 中的比例更低, 同时给定prefix 后第三级code 的条件熵也更低。在更细的movement analysis 中, 有17.32% 的测试目标从多叶same- l_2 bucket 迁移到单叶bucket, 而只有9.68% 迁移到更拥挤的方向。这与我们最初关于local leaf ambiguity 的诊断完全一致。

5.5 TOKENIZER 收益是否传递到了下游SFT

接下来我们把两套最终Industrial tokenizer 推进到下游SFT, 并比较得到的推荐结果。除了当前semantic baseline 和hierarchy-aware tokenizer, 我们还加入项目历史CSV 中最接近当前设定的一条Industrial SFT 记录, 以及历史最强的一条Industrial SFT 记录, 用来判断当前结果在仓库内部的大致位置。

Table 5 给出了一个很重要的限定。Hierarchy-aware tokenizer 并没有直接把系统推成新的end-to-end 最优SFT。相对于当前upstream-aligned baseline, 它提升了NDCG@3 和HR@3, 在@5 上也有轻微增益, 但在@10+ 上仍然落后。这说明tokenizer 侧收益已经可以传到下游, 只不过目前主要停留在短程排序, 而不是全面增益。

Table 5: Industrial 上的SFT 结果。Hierarchy-aware tokenizer 提升了短程排序，但还没有形成广义的@10+ 优势，也没有超过历史最强SFT 设定。

运行	N@1	N@3	N@10	H@1	H@3	H@10
历史最近设置	0.0624	0.0798	0.0987	0.0624	0.0929	0.1471
历史最强设置	0.0671	0.0850	0.1037	0.0671	0.0984	0.1509
当前baseline	0.0631	0.0777	0.0943	0.0631	0.0882	0.1343
当前hierarchy	0.0627	0.0802	0.0936	0.0627	0.0929	0.1304

Table 6: Industrial 上的evaluate 错误分布。Hierarchy-aware tokenizer 明显减少了same-prefix 错误，并且在拥挤局部目标上更有优势；但与此同时，beam 更少停留在baseline 的局部语义邻域中。

指标	Baseline	Hierarchy	Delta
Top-1 error same- l_1 rate	0.1815	0.1236	-0.0580
Top-1 error same- l_2 rate	0.0525	0.0370	-0.0156
Beam contains same- l_1	0.6724	0.5248	-0.1476
Beam contains same- l_2	0.3272	0.3077	-0.0194
Top-1 hit on targets with $l_2 \geq 4$	0.0475	0.0521	+0.0047
Recovery on baseline same- l_2 errors	—	0.0538	—

5.6 EVALUATE 阶段的错误分布发生了什么变化

为了理解这种“局部有提升、整体未全面提升”的现象，我们进一步比较两套SFT 模型在evaluate 阶段的SID-aware 诊断结果。这里关注的不是单纯的aggregate metric，而是错误类型本身是否发生了预期中的变化。

Table 6 说明，下游变化是高度结构化的。积极的一面是，hierarchy-aware tokenizer 确实减少了局部same-prefix 错误：剩余top-1 miss 中，发生在same- l_1 或same- l_2 子树里的比例都明显下降；同时在 l_2 fanout 至少为4 的拥挤目标上，它的top-1 命中率更高。更重要的是，baseline 的same- l_2 错误是hierarchy 最容易恢复的一类错误。这与“hierarchy 正在解决local leaf ambiguity”这一方法动机完全一致。

但诊断同时揭示了另一面：hierarchy-aware tokenizer 的beam 更不容易停留在baseline 的局部语义邻域内。从逐样本比较看，hierarchy 修复了63 个baseline 的top-1 miss，但也打坏了65 个baseline 原本正确的top-1 hit。被修复的样本往往更难、更拥挤：在baseline 下它们的平均目标 l_2 fanout 为7.32，而且target 往往已经在top-3 或top-5 中，只是没有被推到top-1。相反，被打坏的样本往往是baseline 本来就已经进入了正确局部子树的例子。这也就解释了为什么hierarchy 在局部reranking 和短程指标上有帮助，却还没有形成广义的@10+ 增益。

5.7 当前结果的解释

综合来看，当前实验支持一个谨慎但连贯的结论。我们还没有 证明已经得到新的end-to-end 最优系统，也还没有涉及RL，但我们已经证明：

1. 公平的tokenizer 比较必须使用上游MiniOneRec 的训练制度；
2. graph-structured collaborative information 对local same- l_2 disambiguation 确实有信号；
3. 其中最关键的图视图是spectral middle-resolution graph；
4. 将这些图结构以hierarchy-aware regularization 的方式写回semantic tokenizer 之后，最终生成SID 质量优于公平semantic baseline，并且same- l_2 局部歧义显著降低；
5. 这些tokenizer 收益能够以“局部、结构化”的形式传到下游SFT，但当前tokenizer-to-SFT 的接口仍然会牺牲一部分baseline 已经正确的局部routing。

对当前项目阶段而言，这比简单宣称“下游赢了”更有价值。因为我们现在已经知道：方法真正带来的，是对crowded local ambiguity 的修复；而下游没能全面变强的关键，不是方向错了，而是这些结构收益还没有被SFT 充分接住。

6 结论与局限

本文聚焦MiniOneRec的tokenizer阶段,提出了一个更精确的问题:相比统一的feature fusion, graph-structured collaboration 是否应当以level-specific structural supervision的方式进入hierarchical semantic ID学习。基于这一问题,我们提出了MGR-SID v1,它保留semantic RQ-VAE backbone,构建coarse/mid/local三种图视图,并在不同SID level上施加层级感知图正则。实验表明,在upstream-aligned的tokenizer训练制度下,这一设计能够改善最终生成的Industrial SID,并显著降低same- l_2 局部歧义。把该SID推进到Industrial SFT后,我们进一步看到一种“部分传递”的现象:短程排序和拥挤局部样本得到改善,但更广义的@10+推荐质量还没有稳定提升。

当前结果仍有三个明显局限。第一,正式训练时结果目前只在Industrial上完成。第二,当前v1使用的是固定level-to-view assignment,而不是learned allocation。第三,虽然我们完成了第一轮SFT传递实验,但它还没有把tokenizer收益转化为新的end-to-end最优系统,RL也仍然没有启动。这些局限是刻意保留的,因为当前阶段更重要的是先定位“哪里已经对了,哪里还没接住”。

因此,下一步也比之前更具体:不是简单把实验继续堆大,而是优先改进tokenizer-to-SFT transfer。本质上,我们需要保住hierarchy-aware tokenizer对local ambiguity的修复,同时尽量不牺牲baseline原有的coarse-prefix stability。等这一步更稳之后,再继续做repeated-seed SFT、Office验证以及RL。

可复现性说明。本文中所有实验都以增量方式实现于现有OneRec仓库之上。默认baseline主链保持不变; graph-aware tokenizer分支使用独立脚本、配置、日志与输出目录,不会破坏现有流程。

REFERENCES

- Dengzhao Fang, Jingtong Gao, Yu Li, Xiangyu Zhao, and Yi Chang. Prism: Purified representation and integrated semantic modeling for generative sequential recommendation, 2026. URL <https://arxiv.org/abs/2601.16556>.
- Xiaoyu Kong, Leheng Sheng, Junfei Tan, Yuxin Chen, Jiancan Wu, An Zhang, Xiang Wang, and Xiangnan He. Minionerrec: An open-source framework for scaling generative recommendation, 2025. URL <https://arxiv.org/abs/2510.24431>.
- Doyup Lee, Chiheon Kim, Saehoon Kim, Minsu Cho, and Wook-Shin Han. Autoregressive image generation using residual quantization. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 11513–11522. IEEE, 2022. doi: 10.1109/CVPR52688.2022.01123. URL <https://doi.org/10.1109/CVPR52688.2022.01123>.
- Yu Liang, Zhongjin Zhang, Yuxuan Zhu, Kerui Zhang, Zhiluohan Guo, Wenhong Zhou, Zongqi Yang, Kangle Wu, Yabo Ni, Anxiang Zeng, Cong Fu, Jianxin Wang, and Jiazhi Xia. Rethinking generative recommender tokenizer: Recsys-native encoding and semantic quantization beyond llms, 2026. URL <https://arxiv.org/abs/2602.02338>.
- Chang Liu, Yimeng Bai, Xiaoyan Zhao, Yang Zhang, Fuli Feng, and Wenge Rong. Discrec: Disentangled semantic-collaborative modeling for generative recommendation, 2025. URL <https://arxiv.org/abs/2506.15576>.
- Enze Liu, Bowen Zheng, Cheng Ling, Lantao Hu, Han Li, and Wayne Xin Zhao. Generative recommender with end-to-end learnable item tokenization, 2024. URL <https://arxiv.org/abs/2409.05546>.
- Ahmad Bin Rabiah and Julian McAuley. Gsprec: Temporal-aware graph spectral filtering for recommendation, 2025. URL <https://arxiv.org/abs/2505.11552>.
- Shashank Rajput, Nikhil Mehta, Anima Singh, Raghunandan Hulikal Keshavan, Trung Vu, Lukasz Heldt, Lichan Hong, Yi Tay, Vinh Q. Tran, Jonah Samost, Maciej Kula, Ed H. Chi, and Mahesh Sathiamoorthy. Recommender systems with generative retrieval. In *Advances in Neural Information Processing Systems 36*

(*NeurIPS*), 2023. URL http://papers.nips.cc/paper_files/paper/2023/hash/20dcab0f14046a5c6b02b61da9f13229-Abstract-Conference.html.

Huanjie Wang, Xinchun Luo, Honghui Bao, Zixing Zhang, Lejian Ren, Yunfan Wu, Hongwei Zhang, Liwei Guan, and Guang Chen. Pit: A dynamic personalized item tokenizer for end-to-end generative recommendation, 2026. URL <https://arxiv.org/abs/2602.08530>.

Jiafeng Xia, Dongsheng Li, Hansu Gu, Tun Lu, Peng Zhang, Li Shang, and Ning Gu. Frequency-aware graph signal processing for collaborative filtering, 2024. URL <https://arxiv.org/abs/2402.08426>.

Bowen Zheng, Yupeng Hou, Hongyu Lu, Yu Chen, Wayne Xin Zhao, Ming Chen, and Ji-Rong Wen. Adapting large language models by integrating collaborative semantics for recommendation, 2023. URL <https://arxiv.org/abs/2311.09049>.

Jieming Zhu, Mengqun Jin, Qijiong Liu, Zexuan Qiu, Zhenhua Dong, and Xiu Li. Cost: Contrastive quantization based semantic tokenization for generative recommendation, 2024. URL <https://arxiv.org/abs/2404.14774>.

Tianyu Zhu, Yansong Shi, Yuan Zhang, Yihong Wu, Fengran Mo, and Jian-Yun Nie. Collaboration and transition: Distilling item transitions into multi-query self-attention for sequential recommendation, 2023. URL <https://arxiv.org/abs/2311.01056>.

A 附录

A.1 当前实现位置

当前MGR-SID v1 的实现位于仓库中的独立实验分支，不会改动默认MiniOneRec tokenizer 主链。主要入口为：

- `scripts/experiment_mgr_sid_v1_train.py`
- `scripts/experiment_mgr_sid_v1_generate.py`

核心实现位于：

- `src/onerec/experiments/mgr_sid/train_v1.py`
- `src/onerec/experiments/mgr_sid/transplanted_graph_bank.py`
- `src/onerec/experiments/mgr_sid/paper_transplants.py`

A.2 v1 中的GRAPH BANK 设置

Table 7: 当前v1 实验中实际使用的graph-bank 参数。

组件	设定
History window	10
Coarse minimum edge weight	2.0
Local minimum edge weight	1.0
Semantic anchor top- k	32
Semantic anchor mixing weight	0.35
Spectral rank	48
Middle-band eigen ratio	[0.25, 0.65]
Temporal mixing ratio (alt. middle view)	0.35
Graph top- k per row in training	32

Table 8: 用于Table 3 公平比较的upstream-aligned tokenizer 训练制度。

超参数	数值
量化层数	3
Codebook sizes	[256, 256, 256]
Quantized embedding dimension	32
Encoder/decoder widths	[2048, 1024, 512, 256, 128, 64]
Optimizer	AdamW
Learning rate	10^{-3}
Weight decay	0
Scheduler	constant with warmup
Warmup epochs	50
Epochs	10000
Batch size	20480
Quantization loss weight	1.0
β	0.25
Graph loss weights	(0.05, 0.15, 0.05)

A.3 TOKENIZER 训练超参数

A.4 局部歧义分析的解释

本文中的local ambiguity analysis 比较的是final baseline index 与final hierarchy index，而不是直接比较推荐输出。这是一个tokenizer-native 的分析，因此应被理解为对tokenizer 结构本身的证据：

- hierarchy-aware tokenizer 产生了更少拥挤的same- l_2 bucket；
- 这一变化在catalog 级和test-weighted 两种口径下都成立；
- 它与本文的核心动机，即local leaf ambiguity，直接对应。

A.5 初步下游SFT 结果的解释

第一轮下游SFT 应被理解为“部分传递证据”，而不是最终end-to-end claim。

- hierarchy-aware tokenizer 在Industrial 上提升了短程指标：NDCG@3 从0.0777 升到0.0802，HR@3 从0.0882 升到0.0929；
- 但在@10+ 上，它仍然弱于当前semantic baseline；
- 和项目历史CSV 中最强的Industrial SFT 设定相比，当前两条新实验都还没有达到新的最优。

A.6 EVALUATE 错误分布的附加解读

下游错误分析说明，当前SFT 结果之所以是“局部提升、整体未全面提升”，核心在于两类相反效应同时存在：

- hierarchy-aware tokenizer 降低了same- l_1 与same- l_2 类型的top-1 错误；
- 它对拥挤目标，尤其是target l_2 fanout 至少为4 的样本，更有帮助；
- baseline 的same- l_2 错误是最容易被hierarchy 恢复的一类错误；
- 但与此同时，一部分baseline 原本已经进入正确局部子树的样本，会在hierarchy-aware SID 下被打坏，从而影响更广义的@10+ 排序。

A.7 当前稿件的范围

这份稿件应被视为tokenizer-stage draft，而不是完整end-to-end paper。接下来最直接的里程碑包括：

-
1. 对final tokenizer comparison 补做repeated seed 验证;
 2. 在Office 上补齐upstream-aligned tokenizer 实验;
 3. 改进tokenizer-to-SFT transfer, 让local ambiguity 的收益不要打坏原本已经正确的局部routing;
 4. 在SFT 接口更稳定后, 再将新的hierarchy-aware SID 推进到RL;
 5. 等下游指标更强后, 再与更多已发表tokenizer 方法做主表比较。